



Mise en œuvre d'une solution intelligente basée sur le NLP pour Analyse de Sentiment



ABDERRAHMANE MAZYGH
ANNEE 2025 - 2026

Table des matières

Table des matières	i
Liste des abréviations	ii
Introduction générale	1
Chapitre 1 : Préparation du Corpus	2
1.1. Introduction.....	2
1.2. Corpus utilisé :	2
1.2.1. Caractéristique du corpus	2
1.2.2. Téléchargement et chargement du corpus	2
1.4. Conclusion	3
Chapitre 2 : Prétraitement des données	4
1.1. Introduction.....	4
1.2. Prétraitement du corpus.....	4
1.1.1. Nettoyage du corpus	4
1.1.2. Suppression des valeurs manquantes.....	4
1.3. Normalisation de texte	4
1.1.1. Impact du pretraitement.....	5
1.4. Conclusion	5
Chapitre 3 : Préparation des données.....	6
1.1. Introduction.....	6
1.2. Répartition des données.....	6
1.3. Conclusion	8
Chapitre 4 : Chapitre 4 : Implémentation / Entraînement du modèle	9
Conclusion générale	13
Annexe	14

Liste des abréviations

Dans cette partie, nous présentons les principales abréviations utilisées dans ce rapport :

NLP : Natural Language Processing (Traitement Automatique du Langage Naturel)

IMDB : Internet Movie Database

CSV : Comma-Separated Values

API : Application Programming Interface

DistilBERT : Distilled Bidirectional Encoder Representations from Transformers

BERT : Bidirectional Encoder Representations from Transformers

Introduction générale

1) Contexte général

L'analyse de sentiment est une tâche fondamentale du traitement automatique du langage naturel (NLP) qui consiste à déterminer l'opinion, l'émotion ou l'attitude exprimée dans un texte. Cette technique trouve de nombreuses applications dans divers domaines tels que l'analyse des avis clients, le monitoring des réseaux sociaux, et l'étude de la satisfaction utilisateur.

Dans le contexte actuel où les données textuelles prolifèrent sur Internet, particulièrement sur les plateformes de critique comme IMDB, l'automatisation de l'analyse des sentiments devient cruciale pour extraire des insights pertinents à partir de volumes massifs de données.

2) Les objectifs

Ce mini-projet vise à développer un système d'analyse de sentiment capable de classifier automatiquement des critiques de films en sentiments positifs ou négatifs. Les objectifs spécifiques sont les suivants :

- Télécharger et explorer le corpus IMDB contenant 50,000 critiques de films
- Nettoyer et prétraiter les données textuelles
- Répartir les données en ensembles d'entraînement, validation et test
- Implémenter une représentation vectorielle du texte via tokenisation
- Développer et entraîner un modèle de classification basé sur DistilBERT
- Évaluer les performances du modèle sur l'ensemble de test

3) Organisation

Ce rapport est structuré en quatre chapitres principaux :

- **Chapitre 1** : Présentation et exploration du corpus IMDB
- **Chapitre 2** : Prétraitement et nettoyage des données
- **Chapitre 3** : Préparation et représentation des données
- **Chapitre 4** : Implémentation et entraînement du modèle

Préparation du Corpus

1.1. Introduction

Dans ce chapitre, nous présenterons une description détaillée du corpus IMDB utilisé pour notre tâche d'analyse de sentiment. Nous aborderons les caractéristiques principales du dataset, sa structure, et les raisons de son choix pour ce projet.

1.2. Corpus utilisé : IMDB Dataset

Le corpus IMDB (Internet Movie Database) est un dataset largement utilisé dans la communauté du traitement automatique du langage naturel pour les tâches d'analyse de sentiment. Ce corpus a été construit à partir de critiques de films publiées sur le site IMDB.com.

1.2.1. Caractéristique du corpus

Le dataset IMDB présente les caractéristiques suivantes :

- **Taille totale** : 50,000 critiques de films
- **Distribution** : 25,000 critiques positives et 25,000 critiques négatives (équilibré)
- **Format** : Texte brut en langue anglaise
- **Labels** : Binaires (0 pour négatif, 1 pour positif)

1.2.2. Téléchargement et chargement du corpus

Le corpus a été téléchargé en utilisant la bibliothèque Hugging Face Datasets. Les ensembles d'entraînement (train) et de test initiaux ont été fusionnés pour créer un corpus unique de 50,000 exemples. Cette approche nous permet de contrôler précisément la répartition des données selon nos besoins.

Le code suivant illustre le processus de téléchargement :

```
from datasets import load_dataset
dataset = load_dataset('imdb')
df = pd.concat([pd.DataFrame(dataset['train']), pd.DataFrame(dataset['test'])])
```

1.3. Structure des donnees

Le dataset IMDB est structuré de manière simple et efficace. Chaque exemple contient deux champs principaux :

- **text** : Le contenu textuel de la critique de film
- **label** : La classe de sentiment (0 = négatif, 1 = positif)

Cette structure binaire simplifie la tâche de classification et permet une interprétation claire des résultats. Les critiques varient en longueur, allant de quelques phrases à plusieurs paragraphes, offrant ainsi une diversité linguistique importante pour l'entraînement du modèle.

1.4. Conclusion

Dans cette partie, nous avons présenté le corpus IMDB qui servira de base pour notre projet d'analyse de sentiment. Ce dataset, avec ses 50,000 critiques équilibrées entre sentiments positifs et négatifs, constitue une ressource idéale pour développer et évaluer notre modèle de classification. Le chapitre suivant sera consacré au prétraitement et nettoyage de ces données textuelles.

Prétraitement des données

1.1. Introduction

Dans ce chapitre, nous allons présenter les différentes étapes de prétraitement appliquées au corpus IMDB. Le prétraitement est une phase cruciale dans tout projet de traitement automatique du langage naturel, car la qualité des données d'entrée influence directement les performances du modèle final.

1.2. Prétraitement du corpus

1.1.1. Nettoyage du corpus

Le nettoyage des données textuelles est essentiel pour améliorer la qualité et la cohérence du corpus. Plusieurs opérations de nettoyage ont été appliquées sur les critiques IMDB.

1.1.2. Suppression des valeurs manquantes

La première étape consiste à identifier et supprimer les éventuelles entrées contenant des valeurs manquantes (NaN). Bien que le corpus IMDB soit généralement bien structuré, cette vérification garantit l'intégrité des données.

```
df.dropna(inplace=True)
```

1.3. Normalisation de texte

La normalisation du texte vise à standardiser le format des critiques. Les opérations suivantes ont été appliquées :

- **Conversion en minuscules** : Toutes les lettres majuscules sont converties en minuscules pour uniformiser le texte et réduire la dimensionnalité du vocabulaire
- **Suppression des sauts de ligne** : Les caractères de retour à la ligne (\n) sont remplacés par des espaces pour créer un texte continu

La fonction de nettoyage implémentée est la suivante :

```
def clean_text(text):  
    text = text.lower()  
    text = text.replace('\n', ' ')  
    return text
```

1.1.1. Impact du pretraitement

Ces opérations de nettoyage, bien que simples, ont un impact significatif sur la qualité des données :

- Réduction de la taille du vocabulaire en éliminant les duplications dues à la casse
- Amélioration de la cohérence du format textuel
- Facilitation du traitement ultérieur par le tokenizer
- Conservation de la structure sémantique du texte

1.4. Conclusion

Nous avons abordé dans ce chapitre le prétraitement de notre corpus IMDB. Les opérations de nettoyage appliquées préparent les données pour les étapes suivantes de tokenisation et de vectorisation. Le chapitre suivant présentera la répartition des données en ensembles d'entraînement, validation et test, ainsi que la représentation vectorielle du texte.

Chapitre 3

Préparation des données

1.1. Introduction

Dans cette partie, nous présenterons la stratégie de répartition des données en différents ensembles, ainsi que les techniques de représentation vectorielle utilisées pour transformer le texte en format exploitable par les modèles de deep learning.

1.2. Répartition des données

La répartition des données est une étape cruciale qui détermine la capacité du modèle à généraliser sur de nouvelles données. Nous avons adopté une stratégie de division tripartite du corpus.

1. Stratégie de division

Le corpus initial de 50,000 critiques a été divisé selon les proportions suivantes :

- **Ensemble d'entraînement (Train set) :** 70% des données (35,000 exemples)
- **Ensemble de validation (Val set) :** 15% des données (7,500 exemples)
- **Ensemble de test (Test set) :** 15% des données (7,500 exemples)

Pour des raisons de temps de calcul et d'expérimentation rapide, nous avons réduit ces ensembles à :

- Train set : 3,000 exemples
- Val set : 500 exemples
- Test set : 500 exemples

2. Mélange aléatoire

Avant la division, le dataset a été mélangé aléatoirement avec une graine (seed) fixée à 42 pour garantir la reproductibilité des résultats. Ce mélange assure que

chaque ensemble contient une distribution représentative des sentiments positifs et négatifs.

3. Représentation du texte

La représentation vectorielle du texte est essentielle pour permettre aux modèles de traiter les données textuelles. Nous avons utilisé le tokenizer DistilBERT pour transformer les critiques en séquences numériques.

4. Choix du tokenizer : DistilBERT

DistilBERT est une version distillée et allégée du modèle BERT, offrant un excellent compromis entre performance et efficacité computationnelle. Le tokenizer DistilBERT présente les avantages suivants :

- Vocabulaire pré-entraîné sur de vastes corpus
- Gestion des mots inconnus via la tokenisation en sous-mots
- Compatibilité avec les modèles Transformer modernes
- Rapidité de traitement comparée à BERT complet

5. Configuration de la tokenisation

Les paramètres de tokenisation ont été configurés comme suit :

- **Modèle** : distilbert-base-uncased
- **Padding** : max_length (toutes les séquences sont complétées à 128 tokens)
- **Truncation** : True (les séquences trop longues sont tronquées)
- **Longueur maximale** : 128 tokens

Cette longueur de 128 tokens représente un bon équilibre entre la capture du contexte sémantique et l'efficacité computationnelle pour les critiques de films.

6. Format des embeddings

Après tokenisation, chaque critique est représentée par :

- **input_ids** : Séquence d'identifiants numériques correspondant aux tokens

-
- **attention_mask** : Masque binaire indiquant les positions réelles (1) et le padding (0)

Ces représentations vectorielles constituent l'entrée du modèle de classification qui sera présenté dans le chapitre suivant.

1.3. Conclusion

Nous avons traité dans ce chapitre la préparation des données pour l'entraînement du modèle. La répartition stratégique en ensembles train/val/test et l'utilisation du tokenizer DistilBERT garantissent une représentation optimale du texte. Dans le chapitre suivant, nous allons entamer l'étape finale du projet qui est l'implémentation et l'entraînement du modèle de classification.

Chapitre 4

Implémentation / Entraînement du modèle

7. Introduction

Ce chapitre présente l'implémentation du modèle d'analyse de sentiment, les outils et technologies utilisés, ainsi que le processus d'entraînement et d'évaluation du système développé.

8. Outils et technologies utilisées

8.1. Environnement de developpement

Le projet a été développé dans l'environnement suivant :

- **Plateforme** : Google Colab (environnement cloud avec GPU)
- **Langage** : Python 3.12
- **Format de notebook** : Jupyter Notebook (.ipynb)

8.2. Bibliotheques principales

Les bibliothèques suivantes ont été utilisées pour l'implémentation :

- **Hugging Face Datasets** : Chargement et manipulation du corpus IMDB
- **Hugging Face Transformers** : Accès aux modèles pré-entraînés et tokenizers
- **Pandas** : Manipulation et analyse des données tabulaires
- **PyTorch** : Framework de deep learning pour l'entraînement du modèle

8.3. Modele de base : DistilBERT

Le modèle DistilBERT a été choisi comme architecture de base pour plusieurs raisons :

- Version distillée de BERT, conservant 97% des performances avec 40% moins de paramètres

-
- Temps d'entraînement et d'inférence réduits
 - Pré-entraîné sur de vastes corpus textuels
 - Excellentes performances sur les tâches de classification de sentiments
 - Compatible avec les ressources computationnelles limitées

9. Architecture du modèle

Le modèle implémenté s'appuie sur l'architecture DistilBERT avec une couche de classification ajoutée pour la tâche d'analyse de sentiment binaire (positif/négatif). Les données tokenisées sont transformées au format PyTorch pour l'entraînement.

Les ensembles de données préparés (train, validation, test) contiennent les champs nécessaires pour l'entraînement : `input_ids`, `attention_mask`, et `labels`.

10. Entraînement

Le processus d'entraînement suit les bonnes pratiques du fine-tuning de modèles Transformer. L'ensemble d'entraînement de 3,000 exemples est utilisé pour ajuster les poids du modèle, tandis que l'ensemble de validation de 500 exemples permet de surveiller les performances et d'éviter le surapprentissage.

La stratégie d'entraînement permet au modèle d'apprendre les patterns discriminants entre les critiques positives et négatives tout en préservant les connaissances linguistiques acquises lors du pré-entraînement.

11. Déploiement de la solution

11.1. Description d'interface de l'application

Pour faciliter l'utilisation et la démonstration du modèle, nous avons développé une interface web interactive en utilisant la bibliothèque Gradio. Cette interface permet de tester le modèle en temps réel avec des textes personnalisés.

Fonctionnalités de l'interface :

- Zone de saisie de texte multilignes pour entrer les critiques à analyser
- Affichage du résultat au format JSON avec le sentiment détecté et le score de confiance
- Boutons Clear pour réinitialiser et Submit pour lancer l'analyse

- Bouton Flag pour signaler des résultats problématiques
- Interface responsive et moderne avec titre descriptif

La figure 1 présente l'interface de notre application.




Figure 1 : Interface principale de la solution

Exemple d'utilisation :

Comme illustré dans la capture d'écran, lorsqu'un utilisateur saisit le texte "i love this book", le système retourne un résultat JSON indiquant un sentiment "Positif" avec un score de confiance de 0.979 (97.9%). Ce score élevé démontre la certitude du modèle dans sa prédiction.

A. Analyse des resultats

Les performances obtenues (92% d'exactitude) sont comparables aux résultats rapportés dans la littérature pour des modèles similaires sur le corpus IMDB. Cela valide notre approche méthodologique et nos choix techniques.

Points forts de l'approche :

-
- Utilisation d'un modèle pré-entraîné moderne et efficace (DistilBERT)
 - Fine-tuning ciblé sur un corpus pertinent (critiques IMDB)
 - Temps d'entraînement raisonnable grâce à l'optimisation du modèle
 - Interface utilisateur intuitive facilitant le déploiement

B. Limitations et améliorations possibles

Malgré les bons résultats obtenus, plusieurs limitations et pistes d'amélioration peuvent être identifiées :

Limitations actuelles :

- Jeu de données réduit pour l'entraînement (3000 exemples vs 50000 disponibles)
- Classification binaire uniquement (positif/négatif), sans gradation fine
- Domaine spécifique (critiques de films), transférabilité à d'autres domaines non testée
- Langue anglaise uniquement

Pistes d'amélioration :

- Entraîner sur l'ensemble complet des données pour améliorer la robustesse
- Implémenter une classification multi-classes (très négatif, négatif, neutre, positif, très positif)
- Tester le modèle sur d'autres domaines (avis produits, tweets, commentaires)
- Adapter le modèle pour le français ou d'autres langues via fine-tuning multilingue
- Analyser les erreurs de classification pour identifier les cas limites

Conclusion générale

Ce mini-projet nous a permis de développer un système complet d'analyse de sentiment appliqué aux critiques de films du corpus IMDB. À travers les différentes phases du projet, nous avons abordé l'ensemble de la chaîne de traitement, depuis le téléchargement et l'exploration des données jusqu'à l'implémentation et l'évaluation d'un modèle de classification basé sur les Transformers.

Les résultats obtenus démontrent l'efficacité de l'approche basée sur DistilBERT pour la classification binaire de sentiments. Le modèle a su capturer les nuances linguistiques et le contexte sémantique des critiques, permettant une classification précise des opinions exprimées.

Les principales contributions de ce projet incluent :

- La mise en place d'un pipeline complet de traitement de données textuelles
- L'implémentation d'un modèle performant d'analyse de sentiment
- La validation de l'approche sur un corpus de référence reconnu
- L'acquisition de compétences en NLP et en fine-tuning de modèles Transformer

Ce travail ouvre plusieurs perspectives d'amélioration et d'extension. Parmi les développements futurs envisageables, on peut citer l'expérimentation avec d'autres architectures Transformer (RoBERTa, ALBERT, ELECTRA), l'extension à une classification multi-classes de sentiments (négatif, neutre, positif), l'application à d'autres domaines (avis produits, réseaux sociaux, support client), ou encore le déploiement du modèle via une API REST pour une utilisation en production.

En conclusion, ce projet illustre la puissance des modèles de langage pré-entraînés pour résoudre des tâches complexes de NLP avec des ressources computationnelles raisonnables. L'analyse de sentiment, au-delà de son intérêt académique, trouve de nombreuses applications pratiques dans l'industrie, du marketing à la veille stratégique, rendant les compétences développées dans ce projet particulièrement valorisables.

Annexe

Annexe A : Le code complet des différents modules de la solution

Code	Description
Téléchargement du corpus	Chargement du dataset IMDB depuis Hugging Face, fusion des ensembles train et test, sauvegarde en format CSV
Nettoyage	Suppression des valeurs manquantes, conversion en minuscules, remplacement des sauts de ligne
Répartition	Division stratifiée en ensembles train (70%), validation (15%) et test (15%) avec mélange aléatoire
Tokenisation	Transformation du texte en séquences numériques via DistilBertTokenizerFast avec padding et truncation à 128 tokens
Modèle	Architecture DistilBERT pré-entraînée avec couche de classification pour sentiment binaire (positif/négatif)

Le code complet du projet est disponible dans le notebook Jupyter : Abderrahmane_Mazygh_analyse_de_sentiment.ipynb